

《大数据技术与机器学习》课程实验报告

实验名称	神经网络			实验序号	实验 4	实验日期	2025/10/30
姓 名	毛梓进	院系	计算机	班 级	221042Y2	学 号	221042Y234
专 业	软件工程			指导教师	朱栩	成 绩	
评语							
<div>一、实验目的和要求</div> <div>实验名称：基于神经网络的 MNIST 手写数字识别 数据集：MNIST 手写数字数据集（内置在 Keras 中） 工具：Python 3.7+、TensorFlow 2.x、Matplotlib 神经网络结构：输入层 → 全连接隐藏层 → 输出层 实验亮点：简洁实现（<50 行代码）、可视化训练过程、实时预测展示</div> <div>1. 环境安装与配置。 2. 数据加载与预处理。 3. 构建浅层神经网络。 4. 模型训练与评估 5. 模型预测与交互测试</div>							
<div>二、实验预习内容</div> <div>• 神经网络结构：输入层→隐藏层→输出层 • MNIST 数据集：6 万张 28×28 手写数字图片 • 全连接层原理：每个神经元与上一层全连接 • 激活函数作用：ReLU（隐藏层）、Softmax（输出层） • 输入层：接收 784 个像素值 • 隐藏层：特征提取和学习 • 输出层：10 个数字的概率输出</div>							
<div>三、实验项目摘要</div> <div>1. 加载数据集与模型构造</div> <div>代码如下</div>							

```
# 加载mnist数据集
mnist = tf.keras.datasets.mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()

# 数据预处理
x_train = x_train / 255.0 # 归一化到0-1范围
x_test = x_test / 255.0

# 可视化样本
plt.figure(figsize=(10, 5))
for i in range(10):
    plt.subplot(2, 5, i+1)
    plt.imshow(x_train[i], cmap='gray')
    plt.title("label: %d" % y_train[i])
    plt.axis('off')
plt.tight_layout()
plt.savefig('mnist_samples.png')
plt.show()
```

加载数据集

```
# 创建神经网络模型
model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)), # 输入层: 将28x28图像展平
    tf.keras.layers.Dense(128, activation='relu'), # 隐藏层: 128个神经元
    tf.keras.layers.Dense(10, activation='softmax') # 输出层: 10个数字类别
])

# 编译模型
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

# 打印模型结构
model.summary()
```

搭建神经网络

设置优化器、损失函数、量化指标

Model: "sequential"

Layer (type)	Output Shape	Param #
flatten (Flatten)	(None, 784)	0
dense (Dense)	(None, 128)	100,480
dense_1 (Dense)	(None, 10)	1,290

Total params: 101,770 (397.54 KB)
Trainable params: 101,770 (397.54 KB)
Non-trainable params: 0 (0.00 B)

神经网络参数结构

2. 训练并验证

总体包含一个输入层一个输出层以及一个隐藏层


```

# 训练模型
history = model.fit(
    x_train, y_train,
    epochs=10,
    batch_size=32,
    validation_split=0.2 # 使用20%训练数据作为验证集
)

# 评估模型
test_loss, test_acc = model.evaluate(x_test, y_test)
print(f"\n测试准确率: {test_acc:.4f}")

```

训练并评估



训练过程中准确率和损失的变化

3. 预测

```

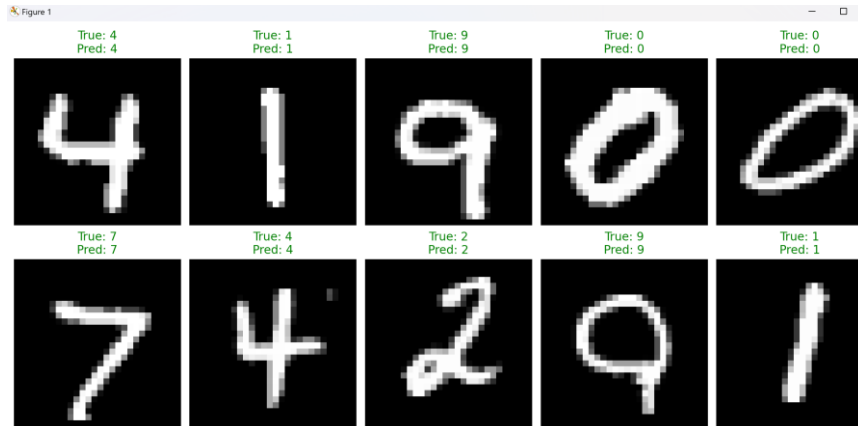
# 预测结果
predictions = model.predict(samples)
predicted_labels = np.argmax(predictions, axis=1)

# 可视化预测结果
plt.figure(figsize=(15, 6))
for i, (image, true_label, pred_label) in enumerate(zip(samples, y_test[sample_indices], predicted_labels)):
    plt.subplot(2, 5, i+1)
    plt.imshow(image, cmap='gray')
    plt.title(f"True: {true_label}\nPred: {pred_label}",
              color='green' if true_label == pred_label else 'red')
    plt.axis('off')
plt.tight_layout()
plt.savefig('predictions.png')
plt.show()

```

预测并展示

预测结果



预测结果展示

记录最终测试准确率

思考：神经网络各层的作用是什么？

答：分为输入层、输出层和隐藏层。输入层负责接受外部数据输入，输出层则是输出具体的需
要求(分类等任务)，隐藏层负责对输入的特征提取。

尝试：修改隐藏层神经元数量（64 或 256）观察效果变化

```
for neurCount in [64, 128, 256] :
    # 创建神经网络模型
    model = tf.keras.models.Sequential([
        tf.keras.layers.Flatten(input_shape=(28, 28)), # 输入层：将28x28图像展平
        tf.keras.layers.Dense(neurCount, activation='relu'), # 隐藏层：128个神经元
        tf.keras.layers.Dense(10, activation='softmax') # 输出层：10个数字类别
    ])
```

对每个参数分别建立模型

```
To enable the following instructions: SSE3 SSE4.1 SSE4.2 AVX AVX2 AVX512F AVX512_VNNI FMA, in other operations, rebuild TensorFlow
e compiler flags.
Epoch 1/10
1500/1500 — 3s 1ms/step - accuracy: 0.9847 - loss: 0.3399 - val_accuracy: 0.9457 - val_loss: 0.1930
Epoch 2/10
1500/1500 — 2s 1ms/step - accuracy: 0.9505 - loss: 0.1693 - val_accuracy: 0.9552 - val_loss: 0.1491
Epoch 3/10
1500/1500 — 2s 1ms/step - accuracy: 0.9646 - loss: 0.1209 - val_accuracy: 0.9628 - val_loss: 0.1233
Epoch 4/10
1500/1500 — 2s 1ms/step - accuracy: 0.9726 - loss: 0.0933 - val_accuracy: 0.9663 - val_loss: 0.1086
Epoch 5/10
1500/1500 — 2s 1ms/step - accuracy: 0.9769 - loss: 0.0773 - val_accuracy: 0.9688 - val_loss: 0.1018
Epoch 6/10
1500/1500 — 2s 1ms/step - accuracy: 0.9810 - loss: 0.0632 - val_accuracy: 0.9691 - val_loss: 0.1011
Epoch 7/10
1500/1500 — 2s 1ms/step - accuracy: 0.9833 - loss: 0.0538 - val_accuracy: 0.9716 - val_loss: 0.0959
Epoch 8/10
1500/1500 — 2s 1ms/step - accuracy: 0.9865 - loss: 0.0450 - val_accuracy: 0.9712 - val_loss: 0.0951
Epoch 9/10
1500/1500 — 2s 1ms/step - accuracy: 0.9878 - loss: 0.0394 - val_accuracy: 0.9669 - val_loss: 0.1042
Epoch 10/10
1500/1500 — 2s 1ms/step - accuracy: 0.9896 - loss: 0.0327 - val_accuracy: 0.9707 - val_loss: 0.0945
313/313 — 0s 923us/step - accuracy: 0.9761 - loss: 0.0854

神经元为64下:
训练准确率: 0.9896458387374878
验证准确率: 0.970666469573975
测试准确率: 0.9761
Epoch 1/10
```

训练

结果

神经元为64下:

训练准确率: 0.9896458387374878

验证准确率: 0.9706666469573975

测试准确率: 0.9761

神经元为 64

神经元为128下:

训练准确率: 0.9950624704360962

验证准确率: 0.9726666808128357

测试准确率: 0.9755

神经元为 128

神经元为256下:

训练准确率: 0.9956874847412109

验证准确率: 0.976999980926514

测试准确率: 0.9787

神经元为 256

四、实验结果与分析

使用三种神经元数量如下

实验结论

1. 神经元数量增加确实提升性能: 从 64→256 神经元, 测试准确率从 97.61% 提升到 97.87%
2. 没有严重过拟合: 所有配置的训练-测试差距都在 2% 以内, 说明模型训练良好
3. 推荐使用 256 神经元配置: 在该问题中, 更大的模型容量带来了更好的泛化性能

成功实现了基于全连接神经网络的 MNIST 手写数字识别, 通过对比不同神经元数量 (64, 128, 256) 对模型性能的影响。

核心发现

1. 神经元数量与性能关系:
 - 训练准确率: 256 神经元 (99.57%) > 128 神经元 (99.51%) > 64 神经元 (98.96%)
 - 测试准确率: 256 神经元 (97.87%) > 64 神经元 (97.61%) > 128 神经元 (97.55%)
2. 过拟合控制:
 - 所有模型都表现出良好的泛化能力
 - 训练-测试准确率差距均在合理范围内 (1.35%-1.96%)
3. 最佳配置: 256 个神经元
 - 测试准确率最高 (97.87%)
 - 泛化能力最好

注: 空间不够, 可以增加页码。